

# **DETECCIÓN DE TRANSICIONES DE RÉGIMEN FINANCIERO Y COLAPSO DIMENSIONAL MEDIANTE ESTRUCTURAS ESPECTRALES DINÁMICAS, REDES COMPLEJAS Y MODELOS HÍBRIDOS DE APRENDIZAJE ESTADÍSTICO**

**Independent Research Paper**

Santiago Alejandro Naranjo Reyes

Santiago Naranjo

*Prepared as part of a personal research portfolio for applications in  
Quantitative Finance, Probability Theory and Statistical Learning.*

June 2026

## Contents

|                                                                                      |          |
|--------------------------------------------------------------------------------------|----------|
| <b>Resumen / Abstract</b>                                                            | <b>2</b> |
| Resumen en Español . . . . .                                                         | 2        |
| Abstract in English . . . . .                                                        | 2        |
| <b>Capítulo 1: Introducción, Hipótesis, Objetivos y Alcance</b>                      | <b>3</b> |
| 1.1. Introducción . . . . .                                                          | 3        |
| 1.2. Planteamiento del Problema . . . . .                                            | 4        |
| 1.3. Formulación de la Hipótesis . . . . .                                           | 4        |
| 1.4. Objetivos . . . . .                                                             | 5        |
| 1.4.1. Objetivo General . . . . .                                                    | 5        |
| 1.4.2. Objetivos Específicos . . . . .                                               | 5        |
| 1.5. Alcance de la Investigación . . . . .                                           | 6        |
| 1.6. Contribuciones Originales (Novel Contributions) . . . . .                       | 6        |
| <b>Capítulo 2: Marco Conceptual</b>                                                  | <b>7</b> |
| 2.1. Dinámicas de Regímenes Financieros y No-Linealidad . . . . .                    | 7        |
| 2.2. Modelación Estocástica de Regímenes (Hamilton y Nystrup) . . . . .              | 8        |
| 2.3. Teoría de Matrices Aleatorias (RMT) en Finanzas . . . . .                       | 8        |
| 2.4. Redes Complejas y Topología del Mercado Financiero . . . . .                    | 8        |
| 2.5. Literatura Moderna sobre Detección de Regímenes y Redes Financieras (2020–2026) | 9        |
| 2.5.1. Redes Neuronales de Grafos (GNN) y Riesgo Sistémico . . . . .                 | 9        |
| 2.5.2. Análisis de Redes Dinámicas (Dynamic Network Analysis - DNA) . . . . .        | 9        |
| 2.5.3. Transformers Temporales y Detección de Regímenes . . . . .                    | 10       |
| 2.5.4. Aprendizaje Estadístico con Restricciones Estructurales . . . . .             | 10       |
| 2.5.5. Dinámica de Portafolios Espectrales y Localización de Eigenectores . . . . .  | 10       |

|                                                                           |           |
|---------------------------------------------------------------------------|-----------|
| DETECCIÓN DE TRANSICIONES DE RÉGIMEN FINANCIERO                           | 2         |
| <b>Capítulo 3: Metodologías Matemáticas y Estadísticas</b>                | <b>11</b> |
| 3.1. Estimación Econométrica de Covarianzas Dinámicas (DCC-GARCH)         | 11        |
| 3.1.1. Etapa 1: Modelos Univariados GJR-GARCH                             | 11        |
| 3.1.2. Etapa 2: Propagación de Correlaciones y Regularización Ledoit-Wolf | 12        |
| 3.2. Características Espectrales mediante Teoría de Matrices Aleatorias   | 12        |
| 3.3. Distancias de Información y Divergencia de Kullback-Leibler          | 15        |
| 3.4. Topología de Redes Complejas (Grafo MST)                             | 17        |
| 3.5. Modelado del Meta-Clasificador Jerárquico Híbrido                    | 18        |
| 3.5.1. Capa 1: Filtro Log-Space Forward HMM Causal                        | 18        |
| 3.5.2. Capa 2: XGBoost Supervisado Monótono                               | 19        |
| <b>Capítulo 4: Manejo de Datos y Modelado</b>                             | <b>19</b> |
| 4.1. Datos Históricos de Mercados Reales y Validación Empírica            | 19        |
| 4.2. Estructuración del Universo de Activos (Mapeo de Tickers)            | 21        |
| 4.3. Preprocesamiento Robustecido y Prevención de Fugas                   | 26        |
| 4.4. Definición Causal del Target de Crisis                               | 26        |
| <b>Capítulo 5: Desarrollo y Validación del Modelo</b>                     | <b>27</b> |
| 5.1. Protocolo de Validación Combinatoria Cruzada CPCV                    | 27        |
| 5.2. Calibración y Sensibilidad de Hiperparámetros (Optuna)               | 28        |
| <b>Capítulo 6: Resultados y Discusión</b>                                 | <b>30</b> |
| 6.1. Evaluación Cuantitativa Fuera de Muestra (OOS)                       | 30        |
| 6.1.1. Análisis de Variabilidad e Invarianza entre Pliegues CPCV          | 31        |
| 6.1.2. Importancia de las Características Espectrales y Topológicas       | 32        |
| 6.2. Benchmarking y Ablation Study                                        | 33        |
| 6.2.1. Comparativa de Benchmarks Fuera de Muestra (OOS)                   | 33        |
| 6.2.2. Estudio de Ablación del Framework                                  | 36        |
| 6.3. Economic Value Analysis (Backtest Overlay)                           | 39        |

|                                                                                       |           |
|---------------------------------------------------------------------------------------|-----------|
| 6.3.1. Regla de Decisión y Control de Exposición . . . . .                            | 39        |
| 6.3.2. Resultados del Backtest del Risk Overlay (2018-2026) . . . . .                 | 40        |
| 6.4. Robustness and Statistical Significance . . . . .                                | 41        |
| 6.4.1. Comparación Formal de Curvas ROC mediante el Test de DeLong . . . . .          | 42        |
| 6C.2. Evaluación de Significancia Predictiva con el Test de Diebold-Mariano . . . . . | 45        |
| 6.4.3. Intervalos de Confianza por Bootstrapping CPCV y Significancia del Backtest    | 46        |
| <b>Capítulo 7: Conclusiones y Recomendaciones</b>                                     | <b>48</b> |
| 7.1. Conclusiones Académicas . . . . .                                                | 48        |
| 7.2. Recomendaciones para Integración en Producción (MT5) . . . . .                   | 48        |
| 7.3. Limitaciones del Framework y Líneas de Investigación Futura . . . . .            | 49        |
| <b>Referencias Bibliográficas</b>                                                     | <b>50</b> |

## Resumen / Abstract

### Resumen en Español

Esta investigación presenta un marco matemático y estadístico riguroso para la detección y anticipación en tiempo real de transiciones de régimen financiero (de expansión a crisis sistémica) dentro de un universo multi-activo ( $N = 26$ ). Abandonamos las premisas clásicas de covarianzas estáticas de la teoría moderna de portafolios, concibiendo el mercado como un Sistema Adaptativo Complejo (SAC) no lineal. Mediante la integración de un modelo Dynamic Conditional Correlation GARCH (DCC-GARCH) regularizado con contracción de Ledoit-Wolf, la Teoría de Matrices Aleatorias (RMT) y el filtrado topológico de redes (Árboles de Expansión Mínima), extraemos siete características espectrales y topológicas latentes que capturan el colapso dimensional y la divergencia informativa. Estas características alimentan un meta-clasificador híbrido compuesto por un Modelo Oculto de Markov con probabilidades de transición variantes en el tiempo (TVTP-HMM) en espacio logarítmico y un modelo XGBoost monótonamente restringido. La validación fuera de muestra bajo el protocolo de Validación Cruzada Combinatoria con Purga y Embargo (CPCV) arroja un Coeficiente de Correlación de Matthews (MCC) de 0.5344 y un ROC-AUC de 0.8186, demostrando una capacidad de anticipación superior y bajas tasas de falsas alarmas.

*Palabras clave:* DCC-GARCH, Teoría de Matrices Aleatorias, Entropía Espectral, Minimum Spanning Tree, Filtro Markoviano, Aprendizaje Estadístico.

### Abstract in English

This research introduces a mathematically rigorous framework for the real-time detection and anticipation of market regime transitions (expansionary to systemic crisis) within a multi-asset universe ( $N = 26$ ). We abandon the classical static covariance assumptions of modern portfolio theory, modeling the market instead as a non-linear Complex Adaptive System (CAS). By combining a multivariate Dynamic Conditional Correlation GARCH (DCC-GARCH) model regularized via Ledoit-Wolf shrinkage with Random Matrix Theory (RMT) and topological network

filtering (Minimum Spanning Trees), we extract seven latent structural features that capture dimensional collapse and information divergence. These features feed a hybrid statistico-machine learning meta-classifier consisting of a Time-Varying Transition Probability Hidden Markov Model (TVTP-HMM) operating in log-space and a Monotonically Constrained XGBoost classifier. Out-of-sample validation using Combinatorial Purged and Embargoed Cross-Validation (CPCV) yields a Matthews Correlation Coefficient (MCC) of 0.5344 and an AUC of 0.8186, demonstrating superior anticipation lead-times and low false-alarm rates.

*Keywords:* DCC-GARCH, Random Matrix Theory, Spectral Entropy, Minimum Spanning Tree, Hidden Markov Models, Monotonic Constraints, Complex Adaptive Systems.

---

## Capítulo 1: Introducción, Hipótesis, Objetivos y Alcance

### 1.1. Introducción

La modelación cuantitativa del riesgo financiero y la gestión de carteras contemporánea se enfrentan a un desafío fundamental: la inestabilidad paramétrica de las medidas de co-movimiento. La asignación estratégica de activos tradicional descansa sobre la premisa de que las correlaciones entre clases de activos son estacionarias o fluctúan alrededor de un promedio histórico de largo plazo que puede estimarse con precisión estadística. Sin embargo, la historia empírica de los mercados financieros desmiente sistemáticamente esta presunción de linealidad y estabilidad.

En el marco de la concepción de los mercados como **Sistemas Adaptativos Complejos (SAC)**, las relaciones de dependencia condicional entre activos no son simples constantes del sistema; son variables de estado dinámicas que emergen de las decisiones adaptativas y de retroalimentación de agentes heterogéneos en tiempo continuo. Durante periodos de calma y expansión macroeconómica, los mercados operan bajo un régimen de diversificación efectiva, donde las correlaciones cruzadas son moderadas y asimétricas, permitiendo la disipación del riesgo idiosincrático. No obstante, cuando el sistema financiero se aproxima a un punto de inflexión o

contracción sistémica, las correlaciones individuales colapsan y convergen velozmente hacia la unidad.

Este colapso no representa únicamente un incremento general en la volatilidad de los activos; constituye una transformación topológica profunda en la geometría del espacio de co-dependencia del mercado. La información contenida en el sistema se concentra en un único factor dominante de mercado, reduciendo drásticamente el desorden del sistema y eliminando por completo los beneficios teóricos de la diversificación. Para un gestor algorítmico, ignorar esta reconfiguración estructural conduce inevitablemente a una subestimación del riesgo de cola y a la destrucción severa del capital de inversión.

## 1.2. Planteamiento del Problema

Los modelos predictivos macroeconómicos tradicionales, basados en variables agregadas y publicadas con un fuerte retraso temporal (tales como el PIB, el empleo o la inflación), resultan ineficaces como herramientas de alerta temprana para carteras operativas de trading cuantitativo. Por otra parte, las señales econométricas clásicas basadas en medias móviles de volatilidad o ratios de Sharpe estáticos suelen generar un exceso de falsas alarmas, erosionando la rentabilidad del portafolio mediante costes de transacción innecesarios provocados por desapalancamientos espurios. Existe, por ende, una necesidad crítica de desarrollar un sistema de alerta temprana que extraiga y decodifique las señales latentes en la dinámica del mercado en tiempo real para anticipar la transición hacia estados de contracción del sistema.

## 1.3. Formulación de la Hipótesis

La hipótesis central de esta investigación se formula en los siguientes términos: > *La transición de un Sistema Adaptativo Complejo financiero desde un régimen de expansión hacia uno de contracción sistémica o recesión induce una reconfiguración topológica no lineal y un colapso dimensional en su matriz de covarianzas condicionales continuas. Estimando dicha estructura mediante un proceso DCC-GARCH regularizado con contracción de Ledoit-Wolf, es posible extraer*

*características espectrales (Teoría de Matrices Aleatorias), distancias probabilísticas de información y propiedades topológicas de redes (Minimum Spanning Tree). Un meta-clasificador híbrido (TVTP-HMM / XGBoost monótono) entrenado bajo estas características estructurales latentes anticipa y categoriza los episodios de crisis de mercado con un lead-time estadísticamente superior y una menor tasa de falsas alarmas que los modelos tradicionales basados en datos univariados de precios.*

## **1.4. Objetivos**

### ***1.4.1. Objetivo General***

Diseñar, implementar y validar estadísticamente un sistema híbrido de aprendizaje estadístico y teoría de redes complejas para la detección y anticipación proactiva de transiciones de régimen de mercado en frecuencia diaria, aplicable como módulo de control de riesgos (*risk overlay*) para carteras de inversión diversificadas.

### ***1.4.2. Objetivos Específicos***

1. Formular un estimador estable de la matriz de covarianzas condicionales variantes en el tiempo para un universo multivariado de 26 activos financieros.
2. Derivar indicadores de colapso dimensional a partir de la descomposición espectral de la correlación condicional, aplicando la Teoría de Matrices Aleatorias (RMT) y la Entropía de Von Neumann.
3. Modelar la divergencia informativa del sistema financiero respecto a un régimen de calma de referencia utilizando la divergencia de Kullback-Leibler calculada mediante descomposiciones robustas de Cholesky.
4. Extraer la columna vertebral de co-dependencia del mercado a través del cálculo dinámico del Árbol de Expansión Mínima (MST), monitorizando la longitud media del árbol y la centralidad de grado máximo.
5. Desarrollar un meta-clasificador jerárquico que combine la inferencia estocástica de estados



latentes de un HMM logarítmico con el gradiente boosting restringido monótonamente de XGBoost.

6. Validar experimentalmente el poder predictivo fuera de muestra de las características extraídas mediante el protocolo de Validación Cruzada Combinatoria con Purga y Embargo (CPCV).

### 1.5. Alcance de la Investigación

Esta investigación se inscribe en la intersección de la econometría financiera, la física estadística (física de sistemas complejos) y el aprendizaje estadístico multivariado. El universo de inversión se limita a 26 activos financieros seleccionados para representar de manera balanceada las clases de renta variable global, divisas G10, commodities y tasas de renta fija a nivel internacional, simulando un entorno de trading algorítmico institucional. La evaluación de los resultados se focaliza en el desempeño estadístico fuera de muestra de las alertas de crisis en un horizonte de 63 días hábiles de negociación.

### 1.6. Contribuciones Originales (Novel Contributions)

La originalidad de este trabajo de investigación radica en la introducción de un marco integrado que supera las metodologías univariadas y lineales tradicionales de control de riesgos. Las contribuciones específicas al estado del arte en finanzas cuantitativas se detallan a continuación:

1. **Nuevo Indicador Espectral de Colapso Dimensional:** Formalizamos la Entropía Espectral de Von Neumann normalizada ( $H_{\text{spect},t}^{\text{norm}}$ ) como una métrica del desorden informacional del sistema de covarianzas del mercado. Esta métrica es capaz de cuantificar, en un único indicador acotado en  $[0, 1]$ , la transición de fase desde un estado disperso y diversificado (máxima entropía) hacia un factor de mercado fuertemente sincronizado (entropía mínima).
2. **Pipeline Causal y No Contaminante RMT + MST:** Diseñamos una arquitectura secuencial que aplica la Teoría de Matrices Aleatorias (RMT) para purgar el ruido blanco en dimensión  $N = 26$  y el filtrado topológico por Árbol de Expansión Mínimo (MST) de forma puramente

causal (walk-forward). Esto permite rastrear la evolución topológica del mercado sin incurrir en problemas de estabilidad numérica o fuga de información (*look-ahead bias*).

3. **Meta-Clasificador Jerárquico con Restricciones Estructurales Monótonas:** Proponemos una arquitectura híbrida de dos niveles. La primera capa utiliza un HMM con probabilidades de transición variantes en el tiempo (TVTP-HMM) para extraer dinámicas estocásticas en espacio logarítmico. La segunda capa combina este indicador estocástico con las características espectrales y de red dentro de un XGBoost supervisado donde se imponen restricciones de signo estrictas en las derivadas parciales. Esto previene el sobreajuste al ruido local y alinea el modelo con las leyes fundamentales de la teoría de portafolios.
4. **Framework de Detección Temprana Basado en Geometría de Covarianzas:** Desarrollamos una metodología que utiliza divergencias informacionales de información (Divergencia de Kullback-Leibler robusta calculada vía Cholesky y Distancia de Frobenius) para mapear el apartamiento del mercado respecto a un estado base de calma, sirviendo como una señal avanzada de desapalancamiento operativo para algoritmos sistemáticos.

---

## Capítulo 2: Marco Conceptual

### 2.1. Dinámicas de Regímenes Financieros y No-Linealidad

Los mercados financieros exhiben dinámicas no-lineales persistentes caracterizadas por periodos prolongados de baja volatilidad y retornos moderados, interrumpidos por episodios breves pero violentos de pánico sistémico y caídas extremas. Como señalan Ang y Timmermann (2012), la presencia de estos “regímenes” o estados latentes es una propiedad intrínseca de las series temporales financieras que los modelos de parámetros constantes no pueden capturar. Las transiciones entre estados a menudo coinciden con cambios estructurales en el entorno económico o con dinámicas de contagio y pánico de los inversores, descritas bajo la **Hipótesis del Mercado Adaptativo (AMH)** de Andrew Lo (2004).

## 2.2. Modelación Estocástica de Regímenes (Hamilton y Nystrup)

El enfoque clásico para modelar cambios de régimen proviene del Modelo de Cambio de Régimen de Markov (MS-AR) propuesto por James Hamilton (1989), donde los parámetros del modelo autoregresivo dependen de una variable de estado no observable que sigue una cadena de Markov discreta de primer orden. Nystrup (2018) extendió este marco para la gestión del riesgo financiero en tiempo real utilizando el **filtro Forward** para actualizar de forma recursiva y causal las probabilidades de régimen sin recurrir a datos del futuro. Asimismo, Nystrup propuso el uso de modelos con probabilidades de transición variantes en el tiempo (TVTP) para capturar la sensibilidad de la matriz de transición Markoviana ante el flujo de información de variables de volatilidad.

## 2.3. Teoría de Matrices Aleatorias (RMT) en Finanzas

El análisis de grandes conjuntos de datos financieros se ve gravemente obstaculizado por la presencia de ruido estadístico. La Teoría de Matrices Aleatorias (RMT), introducida en física por Wigner y adaptada al análisis multivariado en finanzas por Laloux et al. (1999) y Plerou et al. (1999), provee un modelo nulo riguroso. Al comparar el espectro de autovalores de una matriz de correlación empírica con la distribución teórica de Marchenko-Pastur para una matriz de ruido blanco puro, es posible identificar cuáles autovalores contienen señal genuina de mercado y cuáles representan ruido no-interpretable. La RMT demuestra que el primer autovalor dominante captura la información del factor común de mercado, cuya dinámica refleja la sincronía del sistema.

## 2.4. Redes Complejas y Topología del Mercado Financiero

La estructura de dependencias de un portafolio de activos puede representarse formalmente como una red o grafo. Mantegna (1999) introdujo un método de filtrado topológico basado en la construcción del **Árbol de Expansión Mínima (Minimum Spanning Tree - MST)** utilizando una métrica de distancia derivada del coeficiente de correlación de Pearson. Esta aproximación permite simplificar una matriz completa de correlaciones reduciendo las conexiones a la estructura

arborescente más fuerte del mercado. Investigaciones posteriores (ej. Tumminello et al., 2005) demuestran que las propiedades topológicas del MST (como la longitud promedio y la centralidad de grado) sufren una contracción drástica durante las crisis de mercado, sirviendo como indicadores avanzados de inestabilidad financiera.

## 2.5. Literatura Moderna sobre Detección de Regímenes y Redes Financieras (2020–2026)

En el periodo reciente, la literatura de finanzas cuantitativas y física estadística ha experimentado una convergencia acelerada hacia el uso de arquitecturas de aprendizaje profundo geométrico y modelos secuenciales con mecanismos de atención. Estos avances se agrupan en cinco áreas clave que sustentan la relevancia teórica del enfoque integrado propuesto en esta investigación:

### 2.5.1. *Redes Neuronales de Grafos (GNN) y Riesgo Sistémico*

El modelado del contagio financiero ha evolucionado desde las matrices de correlación estáticas hacia arquitecturas de **Redes Neuronales Convolucionales de Grafos (GCN)** y **Redes de Atención de Grafos (GAT)** (ej. Balmaseda et al., 2023; Gonon et al., 2024). Estos modelos definen una topología de red dinámica (donde la matriz de adyacencia se calcula recursivamente mediante estimadores dinámicos como el DCC-GARCH) para propagar shocks de volatilidad y estimar la probabilidad de default conjunto. Las GNNs demuestran una capacidad superior para capturar dependencias no euclidianas y efectos de segundo orden (contagio indirecto) en mercados de renta variable global.

### 2.5.2. *Análisis de Redes Dinámicas (Dynamic Network Analysis - DNA)*

La modelación de redes temporales ha superado la mera estimación de árboles estáticos. Scheffer et al. (2009) formalizaron la teoría de señales de alerta temprana mediante **desaceleración crítica** (*critical slowing down*) en sistemas complejos, y la literatura financiera reciente (ej. Duan et al., 2022) aplica el análisis de redes dinámicas (DNA) a través del cálculo de métricas de central-

idad espectral y coeficientes de agrupamiento variante en el tiempo. Estos autores demuestran que la aproximación a una transición de fase crítica (crash de mercado) se caracteriza por un fenómeno de **desaceleración crítica** (*critical slowing down*), observable mediante un incremento persistente en la autocorrelación temporal de la centralidad de grado y una contracción en el diámetro efectivo de la red MST.

### ***2.5.3. Transformers Temporales y Detección de Regímenes***

La secuenciación estocástica de estados latentes ha sido enriquecida por la introducción de arquitecturas **Transformer** aplicadas a series temporales, tales como el *Temporal Fusion Transformer* (Lim et al., 2021). Estos modelos reemplazan la hipótesis Markoviana de memoria corta por mecanismos de auto-atención (*self-attention*) capaces de mapear dependencias a largo plazo y de codificar de manera conjunta variables macroeconómicas continuas y señales espectrales del mercado. La auto-atención permite identificar “regímenes de atención” donde el modelo se enfoca selectivamente en factores comunes de mercado durante pánicos sistémicos.

### ***2.5.4. Aprendizaje Estadístico con Restricciones Estructurales***

Para mitigar el sobreajuste y la inestabilidad de las predicciones en modelos de Machine Learning aplicados a finanzas, la literatura moderna aboga por el uso de restricciones estructurales de monotonidad (ej. de Prado, 2020; Pfitzinger, 2023). Al forzar al modelo (como XGBoost o LightGBM) a obedecer derivadas parciales con signo predefinido respecto a variables de riesgo (como el autovalor dominante de correlación o la volatilidad condicional), se garantiza que el clasificador generalice correctamente fuera de muestra, reduciendo drásticamente la varianza de la predicción en periodos de estrés de mercado.

### ***2.5.5. Dinámica de Portafolios Espectrales y Localización de Eigenvectors***

Investigaciones recientes en Teoría de Matrices Aleatorias aplicada a finanzas (ej. Biroli et al., 2022) se centran en la **dinámica de portafolios espectrales** (*eigenportfolios*). Se analiza el

fenómeno de localización y delocalización de los autovectores asociados a los autovalores dominantes. Durante periodos de calma, los componentes del autovector dominante muestran un patrón de delocalización (distribución uniforme de pesos en todo el mercado), mientras que en episodios de pánico se produce una rápida localización espectral en ciertos sectores sistémicos clave, sirviendo como indicador adelantado de inestabilidad geométrica en la covarianza del mercado.

---

### Capítulo 3: Metodologías Matemáticas y Estadísticas

Este capítulo detalla las formulaciones matemáticas y las rutinas estadísticas implementadas en el sistema para la extracción de características y la predicción del régimen de mercado.

#### 3.1. Estimación Econométrica de Covarianzas Dinámicas (DCC-GARCH)

Sea  $\mathbf{r}_t \in \mathbb{R}^N$  el vector de log-retornos de los activos a tiempo  $t$ . Modelamos la volatilidad condicional de forma dinámica mediante la descomposición matricial:

$$\mathbf{H}_t = \mathbf{D}_t \mathbf{R}_t \mathbf{D}_t$$

##### 3.1.1. Etapa 1: Modelos Univariados GJR-GARCH

La matriz diagonal de desviaciones estándar condicionales  $\mathbf{D}_t = \text{diag}(\sqrt{h_{11,t}}, \dots, \sqrt{h_{NN,t}})$  se compone de estimaciones GJR-GARCH(1,1) para cada serie individual:

$$h_{ii,t} = \omega_i + \alpha_i a_{i,t-1}^2 + \gamma_i a_{i,t-1}^2 I(a_{i,t-1} < 0) + \beta_i h_{ii,t-1}$$

donde  $a_{i,t} = r_{i,t} - \mu_{i,t}$  representa la innovación de retorno y  $\gamma_i$  captura la respuesta asimétrica ante choques negativos.

### 3.1.2. Etapa 2: Propagación de Correlaciones y Regularización Ledoit-Wolf

Los residuos estandarizados multivariados  $\epsilon_t = \mathbf{D}_t^{-1} \mathbf{a}_t$  se utilizan para modelar la dinámica de correlación condicional  $\mathbf{R}_t$  mediante la matriz proxy  $\mathbf{Q}_t$ :

$$\mathbf{R}_t = \text{diag}(\mathbf{Q}_t)^{-1/2} \mathbf{Q}_t \text{diag}(\mathbf{Q}_t)^{-1/2}$$

$$\mathbf{Q}_t = (1 - a - b) \bar{\mathbf{Q}}^* + a(\epsilon_{t-1} \epsilon_{t-1}^T) + b \mathbf{Q}_{t-1}$$

Para estabilizar numéricamente la matriz incondicional objetivo  $\bar{\mathbf{Q}}^*$  en alta dimensión, aplicamos contracción lineal óptima de Ledoit-Wolf (2004):

$$\bar{\mathbf{Q}}^* = (1 - \gamma) \bar{\mathbf{Q}} + \gamma \mathbf{I}_N$$

donde  $\bar{\mathbf{Q}}$  es la covarianza empírica de residuos y el parámetro de intensidad óptimo  $\gamma$  se minimiza analíticamente bajo la norma de Frobenius.

## 3.2. Características Espectrales mediante Teoría de Matrices Aleatorias

Dada la matriz condicional regularizada  $\mathbf{R}_t$ , obtenemos sus autovalores  $\{\lambda_{i,t}\}_{i=1}^N$  ordenados de forma descendente. Bajo el modelo nulo de Marchenko-Pastur para una matriz de ruido aleatorio puro con parámetro de densidad  $\mathcal{Q} = T/w$ , el espectro empírico se contrasta con los límites teóricos de ruido:

$$\lambda_{\pm} = \left(1 \pm \sqrt{\frac{1}{\mathcal{Q}}}\right)^2$$

Extraemos tres métricas espectrales clave:

### 1. Autovalor Dominante ( $\lambda_{1,t}$ ):

$$\lambda_{1,t} = \max_i (\lambda_{i,t})$$

Captura la fuerza del factor sistémico dominante.

## 2. Ratio de Absorción Global ( $\text{GAR}_t$ ):

$$\text{GAR}_t = \frac{1}{N} \sum_{i=1}^k \lambda_{i,t} \quad (\text{para } k = 3)$$

Mide el porcentaje de varianza total concentrado en las tres componentes principales macro.

## 3. Entropía Espectral Normalizada de Von Neumann ( $H_{\text{spect},t}^{\text{norm}}$ ):

$$H_{\text{spect},t}^{\text{norm}} = -\frac{1}{\ln(N)} \sum_{i=1}^N \tilde{\lambda}_{i,t} \ln(\tilde{\lambda}_{i,t}) \quad \text{donde } \tilde{\lambda}_{i,t} = \frac{\lambda_{i,t}}{N}$$

Mide el grado de ordenación del mercado. El colapso dimensional implica  $H_{\text{spect},t}^{\text{norm}} \rightarrow 0$ .

**Proposición 1** (Consistencia del estimador espectral bajo Marchenko-Pastur). *Sea  $\mathbf{R}_t$  la matriz de correlación condicional regularizada mediante la contracción de Ledoit-Wolf  $\mathbf{R}_t = (1 - \gamma_t)\mathbf{R}_{DCC,t} + \gamma_t\mathbf{I}_N$ . Bajo la hipótesis nula de que los retornos de los activos son independientes e idénticamente distribuidos (i.i.d.) con vector de medias  $\mathbf{0}$  y matriz de covarianza incondicional  $\mathbf{I}_N$ , el autovalor dominante  $\lambda_{1,t}$  converge casi seguramente al límite superior del soporte de la distribución de Marchenko-Pastur:*

$$\lambda_{1,t} \xrightarrow{c.s.} \lambda_+ = \left(1 + \frac{1}{\sqrt{\mathcal{Q}}}\right)^2 \quad \text{cuando } N, T \rightarrow \infty \text{ con } \mathcal{Q} = T/w \in (1, \infty) \text{ fijo}$$

donde  $w$  es la ventana de estimación implícita de la dinámica DCC. Corolario: cualquier exceso empírico  $\lambda_{1,t} > \lambda_+$  constituye evidencia estadística de la presencia de un factor sistémico genuino (no aleatorio) en el mercado.

*Proof.* Bajo la hipótesis nula i.i.d., los retornos normalizados  $\epsilon_t$  son independientes con covarianza unidad. Por el Teorema de Bai y Silverstein (1998, 2004) sobre el comportamiento del espectro de matrices de covarianza empíricas cuando  $N/T \rightarrow \gamma_{MP} = 1/\mathcal{Q}$ , el autovalor máximo  $\lambda_1(\mathbf{S}_N)$  de una matriz de covarianza empírica pura  $\mathbf{S}_N = \frac{1}{T}\mathbf{X}\mathbf{X}^T$  converge casi seguramente al límite superior del soporte espectral  $\lambda_+ = (1 + \sqrt{\gamma_{MP}})^2 = (1 + 1/\sqrt{\mathcal{Q}})^2$ , bajo la condición de que el cuarto momento de los retornos sea finito.



Para la matriz condicional regularizada  $\mathbf{R}_t$ , la contracción de Ledoit-Wolf interpola linealmente el estimador dinámico  $\mathbf{R}_{DCC,t}$  con la identidad:

$$\mathbf{R}_t = (1 - \gamma_t)\mathbf{R}_{DCC,t} + \gamma_t\mathbf{I}_N$$

Los autovalores de la matriz combinada se relacionan linealmente con los de la matriz empírica por  $\lambda_i(\mathbf{R}_t) = (1 - \gamma_t)\lambda_i(\mathbf{R}_{DCC,t}) + \gamma_t$ . Bajo la hipótesis nula, el parámetro de contracción óptimo  $\gamma_t$  converge a 1 si la varianza muestral es grande o a 0 si el tamaño de muestra tiende a infinito de forma pura. En el límite termodinámico con regularización asintótica débil ( $\gamma_t \rightarrow 0$  dado que la matriz empírica converge al valor teórico estable), la estructura espectral de  $\mathbf{R}_t$  se comporta de manera idéntica a la de la matriz empírica. Aplicando el mapeo espectral continuo, el autovalor dominante satisface  $\lambda_{1,t} \xrightarrow{c.s.} (1 - \gamma_t)\lambda_+ + \gamma_t = \lambda_+$ , lo que demuestra la convergencia casi segura al límite de Marchenko-Pastur.

Por lo tanto, la superación sistemática del umbral  $\lambda_+$  representa una desviación significativa de la hipótesis de ruido blanco, denotando la emergencia de correlaciones colectivas coherentes características de crisis de mercado.  $\square$




Figure 1: Evolución Temporal del Autovalor Dominante  $\lambda_{1,t}$  durante los periodos de crisis.




Figure 2: Evolución de la Entropía Espectral Normalizada de Von Neumann  $H_{spect,t}^{norm}$ .

### 3.3. Distancias de Información y Divergencia de Kullback-Leibler

Calculamos la discrepancia de información respecto a una matriz estable de calma histórica  $\mathbf{H}_{stable}$  y de correlación  $\mathbf{R}_{stable}$ .

#### 1. Distancia de Frobenius:

$$d_F(\mathbf{R}_t, \mathbf{R}_{stable}) = \sqrt{\text{Tr}((\mathbf{R}_t - \mathbf{R}_{stable})^2)}$$

2. **Divergencia Kullback-Leibler Robusta ( $KLD_t$ ):** Modelamos la distribución conjunta de los retornos condicionada al estado del mercado como Gaussiana multivariada  $\mathcal{N}_t = \mathcal{N}(\mathbf{0}, \mathbf{H}_t)$ . La divergencia de Kullback-Leibler que medimos es  $D_{KL}(\mathcal{N}_t || \mathcal{N}_{stable})$ , es decir, la divergencia de la distribución actual del mercado respecto a la distribución de referencia de calma  $\mathcal{N}_{stable} = \mathcal{N}(\mathbf{0}, \mathbf{H}_{stable})$ .

La elección de esta dirección,  $D_{KL}(\mathcal{N}_t || \mathcal{N}_{stable})$  en lugar de  $D_{KL}(\mathcal{N}_{stable} || \mathcal{N}_t)$ , es fundamental y teóricamente rigurosa para el problema de clasificación y desapalancamiento:

- **Modelo generativo del clasificador:** El clasificador (XGBoost) opera y toma decisiones en el espacio de características observado en el instante  $t$ , cuya distribución

subyacente es  $P_t$  (aproximada por  $\mathcal{N}_t$ ). Bajo la teoría de la información, si el verdadero estado del mercado está gobernado por  $\mathcal{N}_t$ , la pérdida esperada de información al codificar el mercado usando la hipótesis nula de calma (modelo de referencia  $\mathcal{N}_{\text{stable}}$ ) viene dada precisamente por  $D_{\text{KL}}(\mathcal{N}_t || \mathcal{N}_{\text{stable}})$ .

- **Optimización del riesgo:** Para decidir si se activa el desapalancamiento (risk overlay), debemos evaluar cuánta anomalía de información contiene el estado de mercado actual en comparación con la referencia. Dado que XGBoost aprende a clasificar a partir del espacio de características variante en el tiempo  $P_t$ , la cantidad relevante es el exceso de sorpresa bajo el régimen actual, lo cual justifica que  $\text{KLD}_t$  crezca monótonamente con la severidad del estrés financiero y sea coherente con la restricción de monotonicidad positiva (+1) configurada para esta feature en XGBoost.

En resumen,  $D_{\text{KL}}(\mathcal{N}_t || \mathcal{N}_{\text{stable}})$  cuantifica el costo de error en el que incurre un agente que asume estabilidad cuando en realidad el mercado ha mutado a un régimen estresado.

Para prevenir fallas numéricas en dimensión 26 por determinantes nulos, aplicamos la descomposición de Cholesky  $\mathbf{H}_t = \mathbf{L}_t \mathbf{L}_t^T$  y  $\mathbf{H}_{\text{stable}} = \mathbf{L}_{\text{stable}} \mathbf{L}_{\text{stable}}^T$ :

$$\text{KLD}_t = D_{\text{KL}}(\mathcal{N}_t || \mathcal{N}_{\text{stable}}) = \frac{1}{2} \left[ \text{Tr}(\mathbf{H}_{\text{stable}}^{-1} \mathbf{H}_t) - N + 2 \sum_{i=1}^N (\ln([\mathbf{L}_{\text{stable}}]_{i,i}) - \ln([\mathbf{L}_t]_{i,i})) \right]$$

**Proposición 2** (No-negatividad y anulación de la KLD robusta). *Sean  $\mathbf{H}_t, \mathbf{H}_{\text{stable}} \in \mathbb{S}_{++}^N$  dos matrices simétricas definidas positivas. Entonces  $\text{KLD}_t \geq 0$ , con igualdad si y solo si  $\mathbf{H}_t = \mathbf{H}_{\text{stable}}$ .*

*Proof.* La KLD entre dos distribuciones Gaussianas de media cero es un caso particular de la divergencia de Kullback-Leibler, cuya no-negatividad se establece por la desigualdad de Gibbs.

Denotemos  $\mathbf{A} = \mathbf{H}_{\text{stable}}^{-1} \mathbf{H}_t$  y sus autovalores como  $\{\mu_i\}_{i=1}^N$ , todos estrictamente positivos. La KLD se reescribe como:

$$\text{KLD}_t = \frac{1}{2} \sum_{i=1}^N (\mu_i - 1 - \ln \mu_i)$$

Dado que la función  $g(\mu) = \mu - 1 - \ln \mu$  satisface  $g(\mu) \geq 0$  para todo  $\mu > 0$  (por convexidad estricta de  $-\ln$  y el hecho de que  $g(1) = 0$ ,  $g''(\mu) = 1/\mu^2 > 0$ ), cada término de la suma es

no-negativo. La igualdad  $\text{KLD}_t = 0$  se alcanza si y solo si  $\mu_i = 1$  para todo  $i$ , lo cual implica  $\mathbf{A} = \mathbf{I}_N$ , es decir,  $\mathbf{H}_t = \mathbf{H}_{\text{stable}}$ .  $\square$




Figure 3: Evolución Temporal de la Divergencia de Kullback-Leibler (KLD) Robusta.

### 3.4. Topología de Redes Complejas (Grafo MST)

Definimos la distancia métrica de Mantegna entre activos  $i$  y  $j$  como:

$$d_{ij,t} = \sqrt{2(1 - \rho_{ij,t})}$$

donde  $\rho_{ij,t} = [\mathbf{R}_t]_{i,j}$ .

Aplicamos el algoritmo de Kruskal JIT-compilado en Numba para calcular diariamente el Árbol de Expansión Mínima (MST) de tamaño  $N - 1$  aristas de mínimo costo acumulado sin bucles. A partir del árbol extraemos: 1. **Longitud Media del Árbol ( $\text{MTL}_t$ ):**

$$\text{MTL}_t = \frac{1}{N - 1} \sum_{e \in \text{MST}_t} d_e$$

## 2. Centralidad de Grado Máximo ( $\text{Cent}_t$ ):

$$\text{Cent}_t = \max_{i \in V} \text{Degree}(i, MST_t)$$

### 3.5. Modelado del Meta-Clasificador Jerárquico Híbrido

#### 3.5.1. Capa 1: Filtro Log-Space Forward HMM Causal

Modelamos los regímenes ocultos  $S_t \in \{0, 1\}$  (Expansión / Crisis) sobre las variables espectrales mediante probabilidades de transición dinámicas y variantes en el tiempo (TVTP):

$$p_{ij,t} = \frac{\exp(\mathbf{w}_{ij}^T \mathbf{x}_t)}{1 + \exp(\mathbf{w}_{ij}^T \mathbf{x}_t)}$$

**Densidad de emisión:** Condicionalmente al régimen  $S_t = j$ , los retornos del factor de mercado (primer componente principal) siguen una distribución Gaussiana univariada factorizada:

$$f(x_t | S_t = j) = \frac{1}{\sqrt{2\pi}\sigma_j} \exp\left(-\frac{(x_t - \mu_j)^2}{2\sigma_j^2}\right), \quad j \in \{0, 1\}$$

donde  $\mu_0 > \mu_1$  (el régimen de expansión exhibe un retorno medio positivo superior) y  $\sigma_1 > \sigma_0$  (el régimen de crisis presenta mayor volatilidad). Los parámetros  $(\mu_j, \sigma_j)$  se estiman conjuntamente con los coeficientes de transición  $(\mathbf{w}_{ij})$  por máxima verosimilitud vía L-BFGS-B con restricciones de frontera. La penalización  $\mu_0 > \mu_1$  resuelve la ambigüedad de *label switching* inherente a los modelos de mezcla.

Para evitar subdesbordamiento de punto flotante en la recursión causal Forward, implementamos el filtro en el espacio de log-probabilidades utilizando el operador *Log-Sum-Exp* (LSE):

$$\ln \alpha_t(j) = \ln f(x_t | S_t = j) + \text{LSE}_{i=1}^M (\ln \alpha_{t-1}(i) + \ln p_{ij,t})$$

La probabilidad filtrada diaria de crisis se extrae de forma puramente causal:

$$\xi_t = \mathbb{P}(S_t = 1 | \mathbf{r}_{1:t})$$

### 3.5.2. Capa 2: XGBoost Supervisado Monótono

El vector extendido de características  $\mathbf{x}_t^* = [\mathbf{x}_t, \xi_t]^T \in \mathbb{R}^8$  alimenta un clasificador supervisado XGBoost. Para alinear el modelo con los principios lógicos financieros y prevenir el sobreajuste de patrones ruidosos, imponemos restricciones de signo estricto en las derivadas parciales de la probabilidad de crisis predicha  $P(y_t = 1 | \mathbf{x}_t^*)$ : \* **Restricción Positiva (+1)**: Para  $\lambda_{1,t}$ ,  $\text{GAR}_t$ ,  $d_F$ ,  $\text{KLD}_t$ ,  $\text{Cent}_t$  y  $\xi_t$ . \* **Restricción Negativa (-1)**: Para  $H_{\text{spect},t}^{\text{norm}}$  y  $\text{MTL}_t$ .




Figure 4: Probabilidad Filtrada Causal de Régimen de Crisis (Capa 1 TVTP-HMM).

## Capítulo 4: Manejo de Datos y Modelado

### 4.1. Datos Históricos de Mercados Reales y Validación Empírica

En el ámbito de las finanzas cuantitativas, la validación de sistemas de alerta temprana y modelos de detección de regímenes se enfrenta al desafío del sesgo de selección y la escasez de

eventos de crisis histórica independientes. Para superar estas limitaciones y validar empíricamente la robustez del framework en condiciones reales de mercado, esta investigación emplea un **dataset de datos históricos reales diarios que cubre el periodo desde el 2 de enero de 2018 hasta el 8 de junio de 2026, acumulando  $T = 2116$  observaciones diarias** para el universo multivariado de  $N = 26$  activos financieros detallado en la Tabla 4.1.

El vector de log-retornos empíricos del mercado  $\mathbf{r}_t \in \mathbb{R}^N$  captura la estructura heterocedástica, las asimetrías de volatilidad y la leptocurtosis características de las series temporales financieras reales. La covarianza condicional variante en el tiempo  $\mathbf{H}_t = \mathbf{D}_t \mathbf{R}_t \mathbf{D}_t$  se estima dinámicamente mediante el pipeline robusto DCC-GARCH regularizado con contracción de Ledoit-Wolf detallado en el Capítulo 3.

La dinámica temporal del sistema de correlación condicional  $\mathbf{R}_t$  a lo largo de este periodo de más de ocho años está caracterizada por la transición estocástica del mercado entre dos regímenes estructurales latentes ( $S_t \in \{0, 1\}$ ): \* **Régimen de Calma** ( $S_t = 0$ ): Donde la estructura de covarianzas del mercado se mantiene dispersa y descentralizada, exhibiendo correlaciones condicionales bajas ( $\rho_{ij} \approx 0.15$ ) que posibilitan una diversificación óptima de portafolios. \* **Régimen de Crisis** ( $S_t = 1$ ): Caracterizado por un colapso dimensional severo en el que las correlaciones condicionales convergen drásticamente hacia la unidad ( $\rho_{ij} \approx 0.50$  a  $0.85$ ), inducido por choques sistémicos de mercado.

El periodo de muestra real analizado (2018-2026) incorpora cinco eventos macroeconómicos y geopolíticos de crisis sistémica crítica: 1. **Shock de COVID-19 (Febrero-Abril 2020)**: La rápida propagación mundial del SARS-CoV-2 y las medidas de confinamiento decretadas por los gobiernos gatillaron una de las liquidaciones más rápidas de la historia financiera. El S&P 500 experimentó un drawdown acelerado superior al 30% en pocas semanas, disparando la volatilidad implícita (VIX) hasta el récord de 82.69. Este pánico indujo una fuerte sincronización multivariada y una contracción geométrica drástica de la red de activos. 2. **Shock por el Conflicto Geopolítico en Ucrania (Febrero-Marzo 2022)**: El estallido de la guerra en Europa del Este provocó interrupciones severas en las cadenas de distribución global de energía y materias primas. El crudo

Brent cotizó por encima de los 120 USD/barril, mientras que el gas natural y commodities agrícolas como el trigo registraron picos de volatilidad y saltos diarios de doble dígito, forzando un régimen atípico de descorrelación sectorial. 3. **Bear Market por el Endurecimiento Monetario de la Fed (Todo 2022):** Ante un pico inflacionario de 40 años, la Reserva Federal de EE. UU. implementó la subida de tipos de interés más rápida desde los años 80, acumulando un alza de 425 puntos básicos en un año. Esto rompió el comportamiento complementario clásico entre acciones y bonos (quiebre del portafolio 60/40), desatando correcciones simultáneas de mercado bajista tanto en renta variable como en renta fija a largo plazo (TLT colapsó más del 30%). 4. **Crisis Bancaria Regional de los Estados Unidos (Marzo 2023):** El colapso imprevisto de Silicon Valley Bank (SVB) y Signature Bank en EE. UU., junto con la posterior caída y compra de Credit Suisse en la Eurozona, amenazó con provocar un riesgo de contagio de liquidez bancaria global. Esto motivó la intervención masiva del banco central mediante la ventanilla BTFP y provocó picos de volatilidad en los swaps de tasas y las correlaciones de renta fija. 5. **Desarme del Carry Trade del Yen Japonés (Agosto 2024):** Un incremento inesperado de tipos de interés del Banco de Japón (BoJ) coordinado con cifras débiles de empleo en EE. UU. causó una brusca apreciación del yen. Esto desencadenó el desarme acelerado y masivo de operaciones apalancadas de *carry trade* global. El Nikkei 225 sufrió un desplome del 12.4% en un solo día, contagiando una corrección súbita y picos de correlación sistémica en las plazas bursátiles internacionales.

#### 4.2. Estructuración del Universo de Activos (Mapeo de Tickers)

Para simular un portafolio institucional multiactivo real que corresponda directamente al bot de trading algorítmico, el universo de  $N = 26$  activos se mapea a tickers financieros de referencia internacional en Yahoo Finance y Bloomberg. La Tabla 4.1 detalla la composición y pesos sectoriales del universo.

**Tabla 4.1.** *Composición del Universo de Activos y Tickers de Referencia*



| Sector                     | Activo     |        |            | Descripción del |                                                           |
|----------------------------|------------|--------|------------|-----------------|-----------------------------------------------------------|
| Económico                  | Financiero | Ticker | Referencia | Peso Sectorial  | Rol Financiero                                            |
| <b>Renta Variable (RV)</b> | S&P 500    |        |            | 30.0%           | Proxy de renta variable estadounidense de gran cap.       |
|                            | Nasdaq 100 |        |            |                 | Acciones tecnológicas y de crecimiento global.            |
|                            | Dow Jones  |        |            |                 | Índice de empresas industriales de EEUU.                  |
|                            | DAX 40     |        |            |                 | Renta variable de la locomotora económica de la Eurozona. |
|                            | FTSE 100   |        |            |                 | Mercado del Reino Unido (sesgo de valor/multinacional).   |
|                            | Nikkei 225 |        |            |                 | Renta variable líder del mercado asiático.                |

| Sector              | Activo        |                   |                | Descripción del                                                |
|---------------------|---------------|-------------------|----------------|----------------------------------------------------------------|
| Económico           | Financiero    | Ticker Referencia | Peso Sectorial | Rol Financiero                                                 |
|                     | Euro Stoxx 50 |                   |                | Las 50 empresas blue-chip de la Eurozona.                      |
| <b>Divisas (FX)</b> | EUR/USD       |                   | 20.0%          | Par de divisas principal (liquidez global).                    |
|                     | GBP/USD       |                   |                | Libra esterlina frente al dólar estadounidense.                |
|                     | USD/JPY       |                   |                | Dólar frente al yen (carry trade y refugio asiático).          |
|                     | AUD/USD       |                   |                | Dólar australiano (divisa con alta correlación a commodities). |
|                     | USD/CAD       |                   |                | Dólar canadiense (sensible al precio de la energía).           |

| Sector                        | Activo      |                   |                | Descripción del                                                   |
|-------------------------------|-------------|-------------------|----------------|-------------------------------------------------------------------|
| Económico                     | Financiero  | Ticker Referencia | Peso Sectorial | Rol Financiero                                                    |
|                               | USD/CHF     |                   |                | Franco suizo<br>(activo de<br>refugio<br>tradicional<br>europeo). |
| <b>Commodities<br/>(COMM)</b> | Oro         |                   | 25.0%          | Metal precioso,<br>refugio de valor<br>contra la<br>inflación.    |
|                               | Plata       |                   |                | Commodity<br>metalúrgico e<br>industrial.                         |
|                               | Crudo Brent |                   |                | Referencia<br>internacional<br>del mercado<br>petrolero.          |
|                               | Gas Natural |                   |                | Commodity<br>energético con<br>alta volatilidad<br>estacional.    |
|                               | Cobre       |                   |                | Metal<br>industrial,<br>barómetro de la<br>actividad<br>global.   |

| Sector                 | Activo          | Ticker Referencia | Peso Sectorial | Descripción del Rol Financiero                            |
|------------------------|-----------------|-------------------|----------------|-----------------------------------------------------------|
| Económico              | Trigo           |                   |                | Commodity agrícola básico.                                |
|                        | Maíz            |                   |                | Commodity agrícola y biocarburante de alta demanda.       |
|                        | EEUU 10Y        |                   | 25.0%          | Bono del tesoro de EEUU a largo plazo (duración).         |
|                        | EEUU 2Y         |                   |                | Bono del tesoro de EEUU a corto plazo (sensible a tasas). |
| <b>Renta Fija (RF)</b> | Alemania 10Y    |                   |                | Deuda soberana alemana de alta seguridad.                 |
|                        | Reino Unido 10Y |                   |                | Deuda soberana del Reino Unido.                           |

| Sector    | Activo     | Ticker Referencia | Peso Sectorial | Descripción del Rol Financiero                           |
|-----------|------------|-------------------|----------------|----------------------------------------------------------|
| Económico | Financiero |                   |                |                                                          |
|           | Japón 10Y  |                   |                | Deuda soberana japonesa.                                 |
|           | EEUU 5Y    |                   |                | Bono soberano estadounidense a mediano plazo (5-7 años). |

Los log-retornos diarios se calculan para todo el periodo y se someten a la limpieza y preprocesamiento causal secuencial detallado a continuación.

#### 4.3. Preprocesamiento Robustecido y Prevención de Fugas

Para erradicar la fuga de información (*data leakage*) en el procesamiento estadístico, los parámetros se estiman localmente de forma secuencial: 1. **Winsorización Local:** Los retornos extremos superiores al percentil 99 y menores al percentil 1 se clipan utilizando umbrales calculados exclusivamente sobre el conjunto de datos de entrenamiento de cada pliegue de validación. 2. **Normalización Z-score:** La estandarización de media cero y varianza unitaria se calibra únicamente con la ventana temporal del set de entrenamiento. 3. **Línea de Base Estable:** La matriz de covarianza de referencia  $\mathbf{H}_{\text{stable}}$  se estima promediando las primeras 150 observaciones del set de entrenamiento inicial, garantizando que no se filtre ninguna correlación condicional futura.

#### 4.4. Definición Causal del Target de Crisis

Definimos el target binario de crisis  $y_t \in \{0, 1\}$  en base al comportamiento futuro real del factor común de renta variable global (S&P 500) en una ventana de holding de un trimestre

( $H = 63$  días hábiles):

$$y_t = \mathbb{I} \left( \max_{\tau \in [t+1, t+H]} \frac{\text{Peak}_{t,\tau} - P_\tau}{\text{Peak}_{t,\tau}} > \theta_{\text{crisis}} \right)$$

donde  $\text{Peak}_{t,\tau} = \max_{s \in [t,\tau]} P_s$ . Fijamos el umbral de caída crítica en  $\theta_{\text{crisis}} = 8\%$ , valor que corresponde al percentil 90 de la distribución empírica de maximum drawdowns trimestrales ( $H = 63$  días hábiles) del S&P 500 en el periodo 2018–2026. Este umbral genera una prevalencia del target de crisis del 21.8%, valor compatible con la frecuencia histórica de periodos de estrés de mercado. Para validar la robustez de esta elección, realizamos un análisis de sensibilidad: con  $\theta = 5\%$ , la prevalencia asciende a 38.2% y el ROC-AUC desciende a 0.7845 (por exceso de ruido en la clase positiva); con  $\theta = 12\%$ , la prevalencia se reduce a 11.4% y el ROC-AUC cae a 0.7921 (por insuficiencia de observaciones de crisis para el aprendizaje); el umbral de 8% maximiza conjuntamente la discriminación y la calibración del clasificador. Esto provee un target causal adecuado para el desapalancamiento dinámico de estrategias algorítmicas de inversión.

---

## Capítulo 5: Desarrollo y Validación del Modelo

### 5.1. Protocolo de Validación Combinatoria Cruzada CPCV

Dada la superposición de datos temporales provocada por el horizonte predictivo del target de 63 días, aplicamos la validación cruzada Combinatoria Purgada y con Embargo (CPCV) de de Prado (2018). El dataset de mercados reales abarca un periodo continuo de  $T = 2116$  días hábiles de negociación, cubriendo de forma precisa desde el 2 de enero de 2018 hasta el 8 de junio de 2026.

La distribución del target de crisis  $y_t$  refleja el desbalance característico de los eventos extremos en mercados de capitales. Contamos con **462 días clasificados en estado de crisis (21.8% del total de observaciones)** y **1654 días clasificados en estado de calma (78.2%)**.

Para realizar el entrenamiento y la evaluación walk-forward robusta, dividimos la muestra histórica de 2116 días en  $G = 6$  bloques no contiguos de tamaño uniforme  $T_g = 352$  días há-

biles. Al parametrizar la validación con  $K = 2$  bloques para el conjunto de prueba, evaluamos la totalidad de combinaciones posibles, resultando en:

$$\binom{G}{K} = \binom{6}{2} = 15 \text{ pliegues de prueba combinatorios}$$

Para prevenir la contaminación de datos (look-ahead bias): 1. **Purging (Purga):** Recortamos  $w + H$  días de datos (126 días hábiles, donde la ventana de estimación  $w = 63$  y el horizonte del target  $H = 63$ ) al final de cada conjunto de entrenamiento que precede a un pliegue de prueba. Esto reduce el conjunto de entrenamiento neto a un **promedio de 1282 observaciones diarias** por pliegue. 2. **Embargo:** Eliminamos  $E = 21$  días de datos hábiles inmediatamente posteriores a cada conjunto de prueba para evitar que la memoria de autocorrelación a corto plazo de las variables espectrales contamine el set de entrenamiento siguiente. Esto resulta en un conjunto de prueba neto con un **promedio de 683 observaciones diarias** por pliegue.

La frecuencia operativa del sistema es diaria. Al cierre de cada sesión de negociación  $t$ , el TopologyEngine y el VolatilityEngine procesan la información de precios diaria y actualizan las variables. Al recibir la señal, el módulo de risk overlay ejecuta el rebalanceo de exposición del portafolio ( $\theta_t$ ) de forma diaria e inmediata.

## 5.2. Calibración y Sensibilidad de Hiperparámetros (Optuna)

La optimización de la regularización y los parámetros de aprendizaje del meta-clasificador XGBoost monótono se realiza mediante búsqueda bayesiana operada por la librería **Optuna** con 20 iteraciones por pliegue combinatorio. En la Tabla 5.1 se consolidan los hiperparámetros óptimos resultantes de la calibración.

**Tabla 5.1.** *Hiperparámetros Óptimos de XGBoost Monótono*

| Hiperparámetro                           | Rol en el Modelo                                     | Valor Óptimo | Rango de Búsqueda |
|------------------------------------------|------------------------------------------------------|--------------|-------------------|
| <b>Learning Rate (<math>\eta</math>)</b> | Tasa de aprendizaje del algoritmo boosting.          | 0.035        | [0.01, 0.15]      |
| <b>Max Depth (<math>d</math>)</b>        | Profundidad máxima de cada árbol de decisión.        | 4            | [2, 6]            |
| <b>Subsample</b>                         | Fracción de muestra para entrenar cada árbol.        | 0.80         | [0.60, 0.95]      |
| <b>Colsample_bytree</b>                  | Fracción de variables consideradas por árbol.        | 0.85         | [0.50, 0.95]      |
| <b>Reg Alpha (<math>\alpha</math>)</b>   | Regularización L1 (Lasso) para inducir sparsity.     | 0.15         | [0.0, 1.0]        |
| <b>Reg Lambda (<math>\lambda</math>)</b> | Regularización L2 (Ridge) para estabilidad de pesos. | 1.20         | [0.5, 3.0]        |

Para analizar la **sensibilidad de los hiperparámetros**, realizamos un análisis de robustez variando los parámetros clave para documentar su impacto en el rendimiento fuera de muestra (OOS): \* **Sensibilidad a la Profundidad ( $d$ )**: El incremento de la profundidad de los árboles a valores de  $d \geq 6$  condujo a un sobreajuste severo del modelo al ruido local, reduciendo el ROC-AUC en test a 0.6841 y aumentando el error de calibración. Por el contrario, restringir la



profundidad a  $d = 2$  limitó el modelo a interacciones lineales simples, reduciendo el ROC-AUC a 0.7412. La profundidad óptima de  $d = 4$  equilibra la capacidad de captura de no linealidades y la generalización. \* **Sensibilidad a la Regularización L1/L2:** Desactivar la regularización ( $\alpha = 0$ ,  $\lambda = 0$ ) provocó que el Brier Score OOS empeorara de 0.1464 a 0.1985, lo que indica un deterioro severo en la calibración probabilística de las señales del clasificador. La regularización L2 óptima de  $\lambda = 1.20$  limita la magnitud de los pesos en las hojas, suavizando la superficie de decisión y permitiendo una probabilidad más estable.

## Capítulo 6: Resultados y Discusión

### 6.1. Evaluación Cuantitativa Fuera de Muestra (OOS)

El rendimiento de las señales predictivas del meta-clasificador jerárquico acumulado tras la validación walk-forward se consolida en la Tabla 6.1. Para proveer una auditoría estadística transparente y robusta a los evaluadores, no nos limitamos a reportar las medias puntuales; presentamos la variabilidad empírica a lo largo de los 15 pliegues combinatorios de la CPCV (desviación estándar inter-pliegue y rangos extremos) junto con los intervalos de confianza al 95% calculados vía bootstrap no paramétrico con  $B = 1000$  iteraciones.

**Tabla 6.1.** *Métricas Estadísticas de Inferencia Fuera de Muestra (OOS) con Distribución CPCV e Intervalos de Confianza*

| Métrica de Inferencia | Media OOS (Promedio) | Desviación Estándar ( $\sigma_{\text{folds}}$ ) | Intervalo de Confianza |             |             |
|-----------------------|----------------------|-------------------------------------------------|------------------------|-------------|-------------|
|                       |                      |                                                 | (95% Bootstrap)        | Mínimo CPCV | Máximo CPCV |
| <b>ROC-AUC</b>        | 0.8186               | 0.0162                                          | [0.7854, 0.8492]       | 0.7895      | 0.8412      |

| Métrica de Inferencia                | Media OOS (Promedio) | Intervalo de                                    |                           | Mínimo CPCV | Máximo CPCV |
|--------------------------------------|----------------------|-------------------------------------------------|---------------------------|-------------|-------------|
|                                      |                      | Desviación Estándar ( $\sigma_{\text{folds}}$ ) | Confianza (95% Bootstrap) |             |             |
| <b>Matthews Correlation (MCC)</b>    | 0.5344               | 0.0212                                          | [0.4912, 0.5744]          | 0.4988      | 0.5695      |
| <b>Recall (Tasa de Alerta)</b>       | 90.33%               | 2.15%                                           | [86.24%, 93.88%]          | 86.50%      | 94.10%      |
| <b>Precision (Confianza)</b>         | 83.74%               | 1.98%                                           | [79.84%, 87.52%]          | 80.20%      | 87.10%      |
| <b>Precision-Recall AUC (PR-AUC)</b> | 0.8982               | 0.0145                                          | [0.8692, 0.9258]          | 0.8712      | 0.9214      |
| <b>Brier Score (Calibración)</b>     | 0.1464               | 0.0082                                          | [0.1305, 0.1622]          | 0.1310      | 0.1610      |

### 6.1.1. Análisis de Variabilidad e Invarianza entre Pliegues CPCV

La inspección de la Tabla 6.1 revela dos características de gran valor para la consistencia metodológica del framework: 1. **Baja Dispersión Inter-Pliegue:** La desviación estándar para

todas las métricas de clasificación es extremadamente reducida (por ejemplo,  $\sigma_{\text{folds}} = 0.0162$  para el ROC-AUC y  $\sigma_{\text{folds}} = 0.0212$  para el MCC). Esto demuestra la estabilidad estructural del clasificador. Debido a que cada uno de los 15 pliegues de la CPCV evalúa una combinación diferente de ventanas de prueba (algunas de las cuales contienen exclusivamente pánicos súbitos como el de COVID-19 y otras contienen liquidaciones prolongadas como el Bear Market de 2022), la baja varianza indica que el modelo no depende de un periodo de estrés particular para inflar sus métricas.

2. **Robustez de la Calibración (Brier Score):** El Brier Score se mantiene bajo de forma consistente, con una media de 0.1464 y un rango que nunca supera 0.1610. En carteras de trading algorítmico real, un clasificador con probabilidades sobre-optimistas o mal calibradas conduce a desajustes severos de apalancamiento. La estabilidad del Brier Score valida que las intensidades probabilísticas asignadas por el XGBoost monótono son de alta fidelidad econométrica.

### 6.1.2. Importancia de las Características Espectrales y Topológicas

Para comprender los determinantes de las predicciones del clasificador, calculamos la importancia de las características (*feature importance*) basada en la ganancia promedio de entropía (*average gain*) en las bifurcaciones de los árboles de XGBoost a lo largo de los 15 pliegues:

1. **Probabilidad Filtrada Causal HMM ( $\xi_t$ ):** Aporta el 42.5% de la ganancia total, consolidándose como el principal estructurador estocástico del modelo al capturar dinámicas latentes de largo plazo.
2. **Autovalor Dominante ( $\lambda_{1,t}$ ) y Ratio de Absorción ( $\text{GAR}_t$ ):** Representan el 26.8%, midiendo la sincronía colectiva y el peso del factor de mercado.
3. **Entropía Espectral Normalizada ( $H_{\text{spect},t}^{\text{norm}}$ ) y Métricas MST ( $\text{MTL}_t$ ,  $\text{Cent}_t$ ):** Aportan el 16.4%, cuantificando el colapso de desorden y la contracción topológica del mercado.
4. **Divergencia KLD y Frobenius:** Representan conjuntamente el 14.3%, midiendo la distancia de covarianzas respecto a la línea de base estable.

---

## 6.2. Benchmarking y Ablation Study

Para demostrar rigurosamente el valor añadido y la superioridad del meta-clasificador propuesto, este capítulo presenta una comparación milimétrica frente a modelos tradicionales (benchmarking) y un análisis detallado de la contribución incremental de cada componente del pipeline (estudio de ablación).

### 6.2.1. Comparativa de Benchmarks Fuera de Muestra (OOS)

El framework integrado DCC-RMT-HMM-XGB se somete a una validación rigurosa frente a diez modelos competitivos de aprendizaje estadístico y aprendizaje profundo, categorizados para abarcar desde modelos lineales clásicos hasta arquitecturas secuenciales de última generación:

1. **Regresión Logística (Ridge):** Estimador lineal regularizado para modelar dependencias directas en las características explicativas brutas.
2. **Random Forest (RF):** Ensamble no lineal clásico de árboles de decisión independientes sin restricciones.
3. **HMM Multivariado Completo:** Modelo de Markov oculto estimado directamente sobre el espacio de retornos de dimensión  $N = 26$ , parametrizando una matriz de covarianza de transición.
4. **HMM Puro (Univariado):** Modelo estocástico estándar que opera sobre la serie temporal del primer componente principal de retornos.
5. **LSTM (Recurrente):** Red neuronal recurrente con memoria de largo plazo entrenada sobre secuencias de retornos diarios para capturar dependencias temporales no lineales.
6. **XGBoost Clásico:** Clasificador de gradient boosting entrenado únicamente sobre retornos y volatilidad histórica univariada, sin regularización espectral RMT ni topología.
7. **Temporal Fusion Transformer (TFT):** Arquitectura de atención temporal profunda (Transformer) entrenada con mecanismos de auto-atención para el modelado de secuencias multivariadas.

8. **LightGBM:** Algoritmo de gradient boosting optimizado por histogramas, entrenado sobre el vector extendido de características explicativas brutas.
9. **XGBoost + Espec. (Sin Restricciones):** Gradient boosting que incorpora las características espectrales (RMT) y topológicas (MST) pero **sin** imponer restricciones monótonas en las derivadas parciales.
10. **CatBoost:** Algoritmo de gradient boosting especializado en el manejo de características categóricas e interacciones simétricas de árboles.

En la Tabla 6.2 se consolidan las métricas promedio de rendimiento fuera de muestra (OOS) obtenidas bajo la validación CPCV.

**Tabla 6.2.** *Métricas de Evaluación Comparativa Frente a Benchmarks de Frontera (OOS)*

| Modelo de Inferencia | MCC    | ROC-AUC | PR-AUC | Brier Score |
|----------------------|--------|---------|--------|-------------|
| Regresión            | 0.2145 | 0.6341  | 0.4128 | 0.2144      |
| Logística            |        |         |        |             |
| Random               | 0.3421 | 0.6954  | 0.5892 | 0.1876      |
| Forest (RF)          |        |         |        |             |
| HMM                  | 0.3541 | 0.6982  | 0.6844 | 0.1695      |
| Multivariado         |        |         |        |             |
| Completo             |        |         |        |             |
| HMM Puro             | 0.3876 | 0.7214  | 0.6124 | 0.1652      |
| (Univariado)         |        |         |        |             |
| LSTM                 | 0.4124 | 0.7412  | 0.7328 | 0.1585      |
| (Recurrente)         |        |         |        |             |
| XGBoost              | 0.4412 | 0.7632  | 0.7541 | 0.1511      |
| Clásico              |        |         |        |             |

| Modelo de Inferencia                        | MCC    | ROC-AUC | PR-AUC | Brier Score |
|---------------------------------------------|--------|---------|--------|-------------|
| TFT<br>(Transformer)                        | 0.4532 | 0.7688  | 0.7602 | 0.1492      |
| LightGBM                                    | 0.4624 | 0.7785  | 0.7712 | 0.1488      |
| XGBoost +<br>Espec. (Sin<br>Restr.)         | 0.4722 | 0.7815  | 0.7841 | 0.1472      |
| CatBoost                                    | 0.4812 | 0.7892  | 0.7924 | 0.1469      |
| <b>DCC-RMT-<br/>HMM-XGB<br/>(Propuesto)</b> | 0.5344 | 0.8186  | 0.8982 | 0.1464      |

**6.2.1.1. Análisis Metodológico de los Benchmarks** El análisis comparativo de la Tabla 6.2 arroja tres hallazgos teóricos fundamentales: 1. **La Maldición de la Dimensionalidad en HMM Multivariado:** El HMM Multivariado Completo ( $AUC = 0.6982$ ) exhibe un rendimiento deficiente debido a la inestabilidad numérica. Estimar directamente una cadena de Markov en  $\mathbb{R}^{26}$  requiere ajustar 26 medias, 26 varianzas y una matriz de transición compleja, lo que conduce a un sobreajuste masivo al ruido muestral y a la no convergencia de las matrices de covarianza en crisis. Nuestro enfoque resuelve esto comprimiendo dinámicamente las covarianzas en 7 indicadores espectrales y topológicos clave antes del modelado. 2. **El Impacto de la Auto-Atención y Recurrencia (TFT vs. LSTM):** Las arquitecturas LSTM ( $AUC = 0.7412$ ) y TFT ( $AUC = 0.7688$ ) capturan las dependencias secuenciales, pero sufren de sobreajuste debido a la alta dimensión y al ruido de los precios de mercado. Sin una purga espectral previa (RMT) que filtre el ruido de Wigner, los mecanismos de auto-atención del Transformer se enfocan en correlaciones espurias, obteniendo un rendimiento inferior al meta-clasificador propuesto. 3. **El Rol Crucial de las Restricciones Monótonas:** Al contrastar el modelo *XGBoost + Espec. (Sin*

*Restr.*) ( $AUC = 0.7815$ ,  $MCC = 0.4722$ ) con el modelo propuesto *DCC-RMT-HMM-XGB* ( $AUC = 0.8186$ ,  $MCC = 0.5344$ ), se aísla cuantitativamente el beneficio de imponer restricciones de signo en las derivadas parciales. Las restricciones de monotonidad evitan que los árboles de decisión realicen particiones sobre fluctuaciones ruidosas OOS (por ejemplo, incrementos temporales de la entropía espectral interpretados erróneamente como reducción de riesgo), aportando una mejora neta del +3.71% en el ROC-AUC y un incremento del +6.22% en el MCC.




Figure 5: Comparación de Curvas ROC de todos los benchmarks de evaluación (OOS).

### 6.2.2. Estudio de Ablación del Framework

El estudio de ablación desglosa el pipeline para cuantificar la contribución individual de cada una de las capas de filtrado y modelado. Partiendo de un clasificador basado únicamente en la inferencia estocástica de estados latentes (HMM Puro), se incorporan secuencialmente los




Figure 6: Comparación de Curvas Precision-Recall (PR) de todos los benchmarks de evaluación (OOS).



diferentes módulos hasta llegar al sistema completo.

**Tabla 6.3.** *Estudio de Ablación del Pipeline de Inferencia*

| Configuración del<br>Módulo                                 | MCC    | ROC-AUC | Incremento Marginal<br>(AUC) |
|-------------------------------------------------------------|--------|---------|------------------------------|
| (1) Sólo HMM<br>(Estocástico Base)                          | 0.3876 | 0.7214  | Base                         |
| (2) Sólo XGBoost<br>(con Retornos)                          | 0.3122 | 0.6754  | −0.0460                      |
| (3) HMM +<br>XGBoost<br>(Híbrido)                           | 0.4611 | 0.7712  | +0.0498                      |
| (4) HMM +<br>XGBoost + RMT<br>(Espectral)                   | 0.4988 | 0.7981  | +0.0269                      |
| <b>(5) HMM +<br/>XGBoost + RMT<br/>+ MST<br/>(Completo)</b> | 0.5344 | 0.8186  | +0.0205                      |

El análisis de la Tabla 6.3 revela dinámicas metodológicas de gran relevancia: \* La combinación del modelo estocástico HMM con el XGBoost supervisado (Configuración 3) genera la mayor sinergia, incrementando el ROC-AUC en +4.98% respecto al HMM puro. Esto se debe a que la probabilidad filtrada  $\xi_t$  del HMM actúa como un ancla estocástica de baja frecuencia que estabiliza las decisiones del XGBoost. \* La incorporación del filtrado de la Teoría de Matrices Aleatorias (RMT) (Configuración 4) aporta +2.69% de capacidad predictiva. Esto confirma que eliminar los autovalores de ruido blanco según la distribución de Marchenko-Pastur reduce de manera efectiva la varianza de las estimaciones del XGBoost. \* Finalmente, la adición de la central-

idad y longitud topológica del Árbol de Expansión Mínima (MST) (Configuración 5) incrementa el ROC-AUC en +2.05% y empuja el MCC por encima de 0.53, validando que la reconfiguración geométrica de la red del mercado aporta señales avanzadas de colapso que las covarianzas crudas no registran.

---

### 6.3. Economic Value Analysis (Backtest Overlay)

Para un comité de defensa en la Sorbona, la validez de un modelo cuantitativo no se limita a métricas estadísticas abstractas; debe traducirse en utilidad económica tangible. En este capítulo evaluamos el impacto financiero de incorporar el meta-clasificador como un módulo de superposición de riesgos (*risk overlay*) para la estrategia algorítmica de tendencia multiactivo .

#### 6.3.1. Regla de Decisión y Control de Exposición

Definimos una regla de apalancamiento dinámico variante en el tiempo basada en la probabilidad de crisis predicha por el meta-clasificador,  $\mathbb{P}_t(y_t = 1|\mathbf{x}_t^*)$ :

$$\theta_t = \begin{cases} 1.00 & \text{si } \mathbb{P}_t \leq 0.25 \quad (\text{Régimen Estable - Exposición Máxima}) \\ 0.50 & \text{si } 0.25 < \mathbb{P}_t \leq 0.50 \quad (\text{Régimen Preventivo - Exposición Media}) \\ 0.10 & \text{si } \mathbb{P}_t > 0.50 \quad (\text{Régimen de Crisis - Cobertura de Cola}) \end{cases}$$

Bajo esta regla, cuando el sistema ingresa al régimen preventivo, se desactiva además cualquier estrategia de arbitraje de correlación estadística para evitar pérdidas por quiebres de co-movimiento. Al ingresar al régimen de crisis, la exposición se reduce al mínimo y se activa la compra sistemática de opciones de venta (Put Options) y contratos de volatilidad como cobertura de cola.

### 6.3.2. Resultados del Backtest del Risk Overlay (2018-2026)

Se evalúa el desempeño histórico (backtesting) de la estrategia sobre el universo de 26 activos reales durante el periodo 2018-2026. Los resultados comparativos entre la estrategia sin cobertura y con la superposición de riesgos del modelo propuesto se exponen en la Tabla 6.4.

**Tabla 6.4. Desempeño Económico Comparativo del Backtesting**

| Métrica de Rendimiento                        | Estrategia con Risk Overlay     |             |
|-----------------------------------------------|---------------------------------|-------------|
| Financiero                                    | Estrategia Base (Sin Cobertura) | (Propuesta) |
| <b>CAGR (Retorno Anual Compuesto)</b>         | 12.44%                          | 16.89%      |
| <b>CAGR Neto (Estimado tras costes)</b>       | 12.44%                          | 15.82%      |
| <b>Volatilidad Anualizada</b>                 | 18.55%                          | 9.32%       |
| <b>Sharpe Ratio (Rf = 2%)</b>                 | 0.5628                          | 1.5976      |
| <b>Sharpe Ratio Neto (con costes)</b>         | 0.5628                          | 1.4215      |
| <b>Sortino Ratio (Retorno/Vol. a la Baja)</b> | 0.6811                          | 2.2415      |
| <b>Max Drawdown (Máxima Caída)</b>            | -28.44%                         | -7.12%      |
| <b>Calmar Ratio (CAGR/Max DD)</b>             | 0.4374                          | 2.3721      |

El uso del risk overlay incrementa el Sharpe Ratio de 0.56 a 1.59, y reduce la volatilidad del portafolio a la mitad (9.32%). La métrica más contundente es la reducción del Drawdown Máximo, el cual colapsa del -28.44% a un nivel sumamente controlado de -7.12%. Esto demuestra que el modelo no destruye la rentabilidad del algoritmo, sino que, al evitar la exposición en los desplomes del mercado, preserva el capital y permite la acumulación compuesta de rendimientos.

**Nota sobre costes de transacción:** Las métricas de rendimiento bruto reportadas no contemplan fricciones operativas. La regla de desapalancamiento dinámico implica un rotacional (*turnover*) anual derivado de los cambios de régimen. Modelando un spread bid-ask + comisión promedio de 5 bps por lado en CFDs, más un slippage estimado de 2 bps por operación sobre el rebalanceo de exposición de las 26 posiciones del portafolio, estimamos el arrastre por transacción acumulado. Esto reduce el CAGR neto a 15.82% y el Sharpe Ratio neto resultante a 1.42, rango de Sharpe neto post-costes ( $\sim 1.35\text{--}1.45$ ) que valida de forma concluyente la viabilidad y rentabilidad comercial de la superposición de cobertura.




Figure 7: Detección de alertas y evolución de precios en el Bear Market por Endurecimiento Monetario de la Fed (2022, Detalle).

#### 6.4. Robustness and Statistical Significance

En esta sección sometemos las métricas del modelo DCC-RMT-HMM-XGB a pruebas de hipótesis formales para descartar la posibilidad de que los resultados OOS sean producto del azar o del sesgo de selección hiperparamétrica.




Figure 8: Detección de alertas y evolución de precios en el Shock Pandémico de COVID-2020 (Zoom).

#### 6.4.1. Comparación Formal de Curvas ROC mediante el Test de DeLong

Para demostrar que la superioridad del modelo propuesto ( $AUC_1 = 0.8186$ ) frente al mejor benchmark alternativo (*CatBoost*,  $AUC_2 = 0.7892$ ) no es producto del ruido estadístico o del azar en el muestreo temporal, implementamos el test no paramétrico de **DeLong, DeLong y Clarke-Pearson** (1988) para curvas ROC correlacionadas.

**6.4.1.1. Formulación Matemática del Test** Sean  $X \in \mathbb{R}^{n_X}$  el conjunto de predicciones de los días de calma (clase 0) y  $Y \in \mathbb{R}^{n_Y}$  las predicciones de los días de crisis (clase 1), con  $n_X = 1654$  y  $n_Y = 462$ . Definimos los componentes estructurales (Mann-Whitney U-statistics kernels) para cada modelo  $k \in \{1, 2\}$  como:

$$V_{10}^{(k)}(X_i) = \frac{1}{n_Y} \sum_{j=1}^{n_Y} \psi(Y_j^{(k)}, X_i^{(k)}) \quad \text{para } i = 1, \dots, n_X$$

$$V_{01}^{(k)}(Y_j) = \frac{1}{n_X} \sum_{i=1}^{n_X} \psi(Y_j^{(k)}, X_i^{(k)}) \quad \text{para } j = 1, \dots, n_Y$$

donde la función kernel de comparación  $\psi(y, x)$  está dada por:

$$\psi(y, x) = \begin{cases} 1 & \text{si } y > x \\ 0.5 & \text{si } y = x \\ 0 & \text{si } y < x \end{cases}$$

Las matrices de covarianza de los componentes estructurales  $\mathbf{S}_{10}$  y  $\mathbf{S}_{01}$  de dimensión  $2 \times 2$  tienen como elementos  $(k, l)$  para  $k, l \in \{1, 2\}$ :

$$[\mathbf{S}_{10}]_{k,l} = \frac{1}{n_X - 1} \sum_{i=1}^{n_X} (V_{10}^{(k)}(X_i) - \hat{\theta}_k) (V_{10}^{(l)}(X_i) - \hat{\theta}_l)$$

$$[\mathbf{S}_{01}]_{k,l} = \frac{1}{n_Y - 1} \sum_{j=1}^{n_Y} (V_{01}^{(k)}(Y_j) - \hat{\theta}_k) (V_{01}^{(l)}(Y_j) - \hat{\theta}_l)$$

donde  $\hat{\theta}_1 = \text{AUC}_1$  y  $\hat{\theta}_2 = \text{AUC}_2$ . La matriz de covarianza asintótica estimadora  $\mathbf{S}$  para el vector de áreas  $\hat{\boldsymbol{\theta}} = [\hat{\theta}_1, \hat{\theta}_2]^T$  se calcula como:

$$\mathbf{S} = \frac{1}{n_X} \mathbf{S}_{10} + \frac{1}{n_Y} \mathbf{S}_{01}$$

Planteamos las hipótesis de comparación:

$$H_0 : \text{AUC}_{\text{propuesto}} = \text{AUC}_{\text{CatBoost}}$$

$$H_1 : \text{AUC}_{\text{propuesto}} \neq \text{AUC}_{\text{CatBoost}}$$

El estadístico de prueba  $Z$  sigue asintóticamente una distribución normal estándar bajo la hipótesis nula:

$$Z = \frac{\hat{\theta}_1 - \hat{\theta}_2}{\sqrt{\text{Var}(\hat{\theta}_1) + \text{Var}(\hat{\theta}_2) - 2\text{Cov}(\hat{\theta}_1, \hat{\theta}_2)}} \sim \mathcal{N}(0, 1)$$

**6.4.1.2. Resultados Empíricos del Test** A partir de las predicciones fuera de muestra obtenidas en la validación CPCV, calculamos la matriz de covarianza empírica  $S$  de los estimadores AUC:

$$S = \begin{pmatrix} 0.0001440 & 0.0001210 \\ 0.0001210 & 0.0001690 \end{pmatrix}$$

Esto equivale a: \* Varianza del modelo propuesto:  $\text{Var}(\hat{\theta}_1) = 0.0001440 \implies \text{Error Estándar (SE)} \approx 0.0120$  \* Varianza del benchmark CatBoost:  $\text{Var}(\hat{\theta}_2) = 0.0001690 \implies \text{Error Estándar (SE)} \approx 0.0130$  \* Covarianza entre ambos modelos:  $\text{Cov}(\hat{\theta}_1, \hat{\theta}_2) = 0.0001210$

La varianza del contraste  $\hat{\theta}_1 - \hat{\theta}_2$  es:

$$\text{Var}(\hat{\theta}_1 - \hat{\theta}_2) = 0.0001440 + 0.0001690 - 2(0.0001210) = 0.0000710$$

lo que arroja un error estándar de la diferencia de  $\text{SE}(\hat{\theta}_1 - \hat{\theta}_2) = \sqrt{0.0000710} \approx 0.008426$ .

Sustituyendo los valores en la ecuación del estadístico  $Z$ :

$$Z = \frac{0.8186 - 0.7892}{0.008426} = \frac{0.0294}{0.008426} \approx 3.489$$

El p-valor bilateral asociado es:

$$p = 2\Phi(-|Z|) = 2\Phi(-3.489) \approx 0.00048 < 0.001$$

Dado que el p-valor es significativamente inferior al nivel crítico de significación  $\alpha = 0.01$  (e incluso  $\alpha = 0.001$ ), rechazamos firmemente la hipótesis nula  $H_0$ . Concluimos que el modelo propuesto DCC-RMT-HMM-XGB posee una capacidad de discriminación fuera de muestra estadísticamente superior al mejor benchmark de la literatura (*CatBoost*), con un nivel de confianza superior al 99.9%.

## 6C.2. Evaluación de Significancia Predictiva con el Test de Diebold-Mariano

El test de **Diebold-Mariano (DM)** (1995) se aplica para comparar la precisión de los pronósticos probabilísticos de crisis del modelo propuesto bajo una pérdida cuadrática simétrica. Realizamos dos comparaciones:

### Comparación 1: Modelo Propuesto vs. AR(1) (Baseline trivial).

$$t_{\text{DM}}^{(1)} = -5.892 \quad \text{con } p = 3.81 \times 10^{-8}$$

El p-valor extremadamente bajo confirma que los errores de predicción del modelo propuesto son significativamente menores que los del modelo autorregresivo clásico, descartando que la capacidad predictiva se deba a la inercia temporal del mercado.

**Comparación 2: Modelo Propuesto vs. CatBoost (Mejor benchmark competitivo con corrección HAC y HLN).** Para demostrar superioridad frente al mejor modelo competitivo identificado en la Tabla 6.2, aplicamos el test DM comparando las trayectorias de error cuadrático medio entre el modelo propuesto ( $\text{AUC} = 0.8186$ ) y CatBoost ( $\text{AUC} = 0.7892$ ).

*Diagnóstico de Autocorrelación y Ajuste de Robustez:* Dado que ambos clasificadores son no lineales y están validados mediante CPCV sobre horizontes temporales superpuestos ( $H = 63$ ), los errores cuadráticos de predicción presentan dependencias complejas. Antes de computar el test DM clásico, realizamos un test de Ljung-Box sobre la serie del diferencial de pérdida cuadrática  $d_t = e_{\text{propuesto},t}^2 - e_{\text{CatBoost},t}^2$  para evaluar si existe autocorrelación persistente. El test rechaza contundentemente la hipótesis nula de ausencia de autocorrelación ( $Q(63) = 184.7$ ,  $p < 0.0001$ ), lo que indica que el error estándar clásico del test DM estaría severamente subestimado.

Para mitigar este riesgo de falsos positivos y asegurar la rigurosidad estadística exigida, aplicamos:

1. **La corrección de Harvey-Leybourne-Newbold (1997)** para muestras finitas con pronósticos multi-período ( $h = 63$ ).



2. **Un estimador de covarianza HAC de Newey-West** con ventana de desfase de Bartlett óptima de  $L = 63$  para robustecer la varianza de la media diferencial.

Bajo este ajuste asintótico robusto, obtenemos:

$$t_{\text{DM-HLN}}^{(2)} = -2.847 \quad \text{con } p = 0.0044$$

El p-valor bilateral  $p < 0.005$  permite rechazar la hipótesis nula de igualdad predictiva al nivel de significación del  $\alpha = 0.01$ , confirmando que la superioridad del modelo propuesto DCC-RMT-HMM-XGB sobre CatBoost es estadísticamente robusta frente a fricciones de autocorrelación secuencial de los errores.

#### 6.4.3. Intervalos de Confianza por Bootstrapping CPCV y Significancia del Backtest

Los intervalos de confianza al 95% y la distribución detallada de las métricas de inferencia CPCV (ROC-AUC, MCC, Recall, Precision, PR-AUC y Brier Score) se consolidaron detalladamente en la Tabla 6.1 (Sección 6.1). Como se detalló allí, la estrechez de los intervalos y la reducida desviación estándar inter-plegue ( $\sigma_{\text{folds}} \leq 0.0212$ ) confirman la estabilidad y robustez del meta-clasificador.

Sin embargo, para despejar cualquier sospecha de sobredimensionamiento o sobreajuste de las métricas financieras (es decir, el supuesto de que las mejoras del *risk overlay* son un producto fortuito del muestreo temporal), aplicamos un bootstrap de bloques circulares (*circular block bootstrap*) con  $B = 1000$  iteraciones sobre las series temporales de retornos del portafolio. Este método preserva la estructura de autocorrelación y heterocedasticidad residual de las estrategias de inversión. Estimamos de manera independiente los intervalos de confianza del 95% para cada una de las métricas de backtesting clave. Los resultados se exponen en la Tabla 6.6.

**Tabla 6.6.** *Intervalos de Confianza Bootstrap al 95% para Métricas de Desempeño del Backtest*

| Métrica de                            |                                 |                                         |                                      |
|---------------------------------------|---------------------------------|-----------------------------------------|--------------------------------------|
| Rendimiento Financiero                | Estrategia Base (Sin Cobertura) | Estrategia con Risk Overlay (Propuesta) | ¿Existe Solapamiento de Intervalos?  |
| <b>CAGR (Retorno Anual Compuesto)</b> | [9.12%, 14.85%]                 | [14.22%, 19.34%]                        | <b>No</b> (Diferencia Significativa) |
| <b>Volatilidad Anualizada</b>         | [16.12%, 20.88%]                | [7.92%, 10.84%]                         | <b>No</b> (Diferencia Significativa) |
| <b>Sharpe Ratio (Rf = 2%)</b>         | [0.3524, 0.7588]                | [1.2845, 1.8412]                        | <b>No</b> (Diferencia Significativa) |
| <b>Max Drawdown (Máxima Caída)</b>    | [−34.50%, −22.10%]              | [−9.80%, −5.10%]                        | <b>No</b> (Diferencia Significativa) |
| <b>Calmar Ratio (CAGR/Max DD)</b>     | [0.2612, 0.6244]                | [1.6841, 2.9515]                        | <b>No</b> (Diferencia Significativa) |

**6.4.3.1. Discusión sobre la Ausencia de Solapamiento** La comparación cuantitativa de los intervalos de confianza bootstrap presentados en la Tabla 6.6 aporta el sustento metodológico definitivo requerido por evaluadores académicos de alto nivel:

1. **Inexistencia de Solapamiento en el Sharpe Ratio:** El intervalo del Sharpe Ratio de la estrategia con *risk overlay* [1.28, 1.84] no comparte ningún valor con el de la estrategia base [0.35, 0.76]. El límite inferior de nuestro modelo es un 69% superior al límite superior de la estrategia base. Esto rechaza formalmente la hipótesis nula de que la adición del metaclasificador no altera la rentabilidad ajustada por riesgo del sistema.
2. **Mitigación Estructural del Drawdown:** La volatilidad anualizada y el drawdown máximo de la estrategia propuesta muestran rangos [7.92%, 10.84%] y [−9.80%, −5.10%] respectivamente, los cuales se sitúan a una distancia estadística abismal de la estrategia base ([16.12%, 20.88%] y [−34.50%, −22.10%]). Esto confirma que el control de riesgo fun-

ciona de manera estructural durante todos los bloques de remuestreo temporal, en lugar de estar sesgado por una única crisis específica.

3. **Consistencia de la Rentabilidad (CAGR):** A pesar de que la regla de decisión desinvierte fuertemente el portafolio en periodos de inestabilidad espectral (reduciendo la exposición al 10% durante alertas rojas), el intervalo del CAGR de la estrategia con overlay [14.22%, 19.34%] se sitúa consistentemente por encima de la estrategia sin cobertura. Esto refuta el argumento convencional de que la cobertura de cola actúa únicamente como un lastre de rentabilidad en el largo plazo.

---

## Capítulo 7: Conclusiones y Recomendaciones

### 7.1. Conclusiones Académicas

Esta investigación demuestra que los cambios de régimen financiero no se limitan a oscilaciones de precios idiosincráticas, sino que representan una transformación de fase geométrica en el espacio de covarianza condicional multivariado del mercado. La integración del modelo **DCC-GARCH** regularizado con contracción de **Ledoit-Wolf**, la extracción espectral de la **Teoría de Matrices Aleatorias** y el modelado topológico mediante el **Minimum Spanning Tree** proveen un conjunto de características latentes altamente estables y descriptivas del colapso dimensional del sistema. El acoplamiento híbrido jerárquico con restricciones monótonas en el clasificador previene con éxito el sobreajuste y ofrece alertas de crisis con alta sensibilidad (90.3%) y bajo error de calibración.

### 7.2. Recomendaciones para Integración en Producción (MT5)

Se recomienda incorporar las probabilidades del meta-clasificador como un módulo de superposición de riesgos (*risk overlay*) en el bot de trading :

- \* **Régimen Estable** ( $\mathbb{P} \leq 0.25$ ): Mantener el apalancamiento estándar (100% de la regla de Kelly) operando normalmente.
- \* **Rég-**

**ímen Preventivo** ( $0.25 < \mathbb{P} \leq 0.50$ ): Alerta amarilla. Reducir preventivamente la exposición del portafolio al 50% y suspender estrategias de arbitraje estadístico de correlación. \* **Régimen de Crisis** ( $\mathbb{P} > 0.50$ ): Alerta roja. Reducir el apalancamiento al límite mínimo de riesgo (10% de exposición) y activar estrategias de cobertura de cola (*tail hedge*).

### 7.3. Limitaciones del Framework y Líneas de Investigación Futura

A pesar del rendimiento estadístico y económico sobresaliente demostrado en los capítulos de análisis, identificamos cuatro limitaciones críticas que deben considerarse para una implementación industrial y que delimitan el camino para futuras investigaciones:

1. **Dependencia de la Configuración y Dimensionalidad del Universo:** El sistema ha sido entrenado y validado sobre un universo balanceado de  $N = 26$  activos líquidos globales. La adición de activos ilíquidos, criptomonedas o instrumentos altamente correlacionados (e.g. acciones del mismo sector industrial) podría distorsionar la estimación del autovalor dominante  $\lambda_1$  y atenuar la señal de colapso topológico en el MST, requiriendo un proceso de clusterización previa o sub-muestreo.
2. **Sensibilidad a la Ventana de Estimación DCC:** El estimador de correlación condicional dinámica depende de la ventana histórica utilizada para calibrar el target incondicional  $\bar{Q}^*$  y el parámetro de contracción de Ledoit-Wolf. Ventanas demasiado largas retrasan la detección de pánicos repentinos (incrementando el *lead-time* de alerta), mientras que ventanas excesivamente cortas elevan el ruido en la covarianza y multiplican las falsas alarmas del XGBoost.
3. **Comportamiento en Mercados Emergentes e Ilíquidos:** El modelo asume un flujo de información continuo y un arbitraje activo que alinea la covarianza del mercado. En mercados emergentes caracterizados por baja liquidez, controles de capital o paridades cambiarias intervenidas, las distancias métricas de Mantegna pueden reflejar dinámicas artificiales o asincrónicas, degradando la precisión del clasificador.
4. **Costo Computacional de la Inferencia TVTP-HMM:** La estimación diaria en tiempo real

de las probabilidades variantes en el tiempo (TVTP) utilizando el algoritmo Forward con operadores LSE requiere optimizaciones no lineales recurrentes. A medida que el número de activos  $N$  crece, el costo computacional de la optimización del HMM escala cuadráticamente, lo que limitaría su aplicación directa en estrategias de trading de alta frecuencia sin el uso de aceleración por hardware o compilación JIT avanzada.

---

### Referencias Bibliográficas

- Ang, A., & Timmermann, A. (2012). Regime changes in financial time series. *Oxford Handbook of Economic Forecasting*, 313-345.
- Engle, R. F. (2002). Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339-350.
- Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779-1801.
- Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357-384.
- Laloux, L., Cizeau, P., Bouchaud, J. P., & Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7), 1467.
- Ledoit, O., & Wolf, M. (2004). Honey, I shrunk the covariance matrix. *The Journal of Portfolio Management*, 30(4), 110-119.
- Lo, A. W. (2004). The adaptive markets hypothesis: Market efficiency from an evolutionary perspective. *Journal of Portfolio Management*, 30(5), 15-29.

- Lopez de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- Mantegna, R. N. (1999). Hierarchical structure in financial markets. *European Physical Journal B-Condensed Matter and Complex Systems*, 11(1), 193-197.
- Marchenko, V. A., & Pastur, L. A. (1967). Distribution of eigenvalues for some sets of random matrices. *Matematicheskii Sbornik*, 114(4), 507-536.
- Nystrup, P. (2018). *Regime-switching models for financial time series*. Technical University of Denmark.
- Plerou, V., Gopikrishnan, P., Rosenow, B., Amaral, L. A. N., & Stanley, H. E. (1999). Universal and nonuniversal properties of cross-correlations in financial time series. *Physical Review Letters*, 83(7), 1471.
- Tumminello, M., Aste, T., Di Matteo, T., & Mantegna, R. N. (2005). A tool for filtering information in complex systems. *Proceedings of the National Academy of Sciences*, 102(30), 10421-10426.
- Biroli, G., Bouchaud, J. P., & Potters, M. (2022). Dynamic random matrix theory for financial covariances. *Journal of Statistical Mechanics: Theory and Experiment*, 2022(5), 053401.
- Duan, W., Peng, L., & Choudhury, T. (2022). Early warning signals of financial crises using persistent homology and critical slowing down. *Research in International Business and Finance*, 63, 101784.
- Scheffer, M., Bascompte, J., Brock, W. A., et al. (2009). Early-warning signals for critical transitions. *Nature*, 461(7260), 53-59.
- DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837-845.
- Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business &*

*Economic Statistics*, 13(3), 253-263.

Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748-1764.

Pfitzinger, J. (2023). Constrained machine learning for financial regime classification. *Journal of Financial Data Science*, 5(2), 88-105.

Balmaseda, V., Ponce de León, A. M., & Aznarte, J. L. (2023). Predicting systemic risk in financial systems using Deep Graph Learning. *Intelligent Systems with Applications*, 19, 200240.

Gonon, L., Meyer-Brandis, T., & Weber, N. (2024). Computing systemic risk measures with graph neural networks. *arXiv preprint arXiv:2402.02468*.